

C 题 物流网络分拣中心货量预测及人员排班

摘 要

电商物流网络中分拣中心是一个关键的环节，负责将订单按照不同的流向进行分拣以便将包裹送达到消费者手中。因此提升分拣中心的管理效率对整体网络的履约效率和运营成本至关重要。本文主要根据分拣中心的历史货量与物流网络配置等信息来预测分拣中心每天或者每小时的货量。同时需要根据货物的预测结果对人员进行排班。

针对第一个问题，题目要求利用分拣中心的历史货量数据构建货量预测模型，对 57 个分拣中心未来 30 天每天及每小时的货量进行预测。我们采用 LSTM 模型根据每个分拣中心历史的历史货量数据来对此时序预测任务进行建模，首先将历史数据整理为时序数据，然后初始化 LSTM 模型进行训练并进行评估，最后对 57 个分拣中心未来 30 天每天及每小时的货量进行预测。

针对第二个问题，题目在第一问的基础上增加了运输线路这一维度数据，需要在运输线路发生变化时对分拣中心的货量进行预测。我们利用与第一问类似的做法，首先将附件三中的涉及的数据进行处理，然后利用始发分拣中心、到达分拣中心的路线、货量作为特征构建并训练 LSTM 模型。对于新增路线，我们对附件三、四进行合并确定新增运输路线的情况，以附件 3 中的平均货量作为其初始货量。最后，用训练得到的模型对附件 4 中每个分拣中心的货量进行预测。

关键词：物流网络、LSTM

目录

摘 要 1

1 引言 3

 1.1 问题背景 3

 1.2 问题重述 3

2 模型假设 3

3 问题一 4

 3.1 数据描述和问题一分析 4

 3.2 模型的建立 5

 3.3 问题一求解 7

4 问题二 9

 4.1 数据描述与问题二分析 9

 4.2 问题二求解 10

5 模型评估与进一步讨论 11

 5.1 模型的优点 11

 5.2 模型的缺点 11

 5.3 总结 11

6 参考文献 12

1 引言

1.1 问题背景

电商物流网络中，分拣中心是至关重要的环节，它负责将订单按照不同的流向进行分拣，以确保包裹能够快速准确地送达消费者手中。对分拣中心的货量预测是电商物流网络中一个关键的研究问题，准确的货量预测是后续管理和决策的基础。如果管理者能够提前了解各个分拣中心未来一段时间需要处理的货量，就可以提前做好资源安排，从而提高效率并降低成本。因此，分拣中心管理效率的提升对整体网络的履约效率和运营成本有着重要的影响。

本文旨在利用模型算法通过分析物流中心的数据，包括货量、货物流向、包裹分拣速度等信息，结合模型算法，可以实现更精准的货量预测与人员排班计划。这样的优化能够有效地调配人力资源，使得物流中心在不同时间段和不同工作需求下都能够保持高效运转，提高订单处理速度，降低等待时间，进而提升客户满意度并降低运营成本。

1.2 问题重述

问题一：建立货量预测模型，对 57 个分拣中心未来 30 天每天及每小时的货量进行预测，将预测结果写入结果表 1 和表 2 中。

问题二：过去 90 天各分拣中心之间的各运输线路平均货量如附件 3 所示。若未来 30 天分拣中心之间的运输线路发生了变化，具体如附件 4 所示根据附件 1-4，请对 57 个分拣中心未来 30 天每天及每小时的货量进行预测。并将预测结果写入结果表 3 和表 4 中

2 模型假设

1、数据可信度与完整性：假设提供的数据是真实有效的，并且可能包含一些异常情况，但这些异常情况也是合理存在的。

2、缺失值处理：假设我们对缺失值的处理方式不会对预测结果产生显著影响。

3、新旧路线变化影响：假设新旧路线的变化直接影响到货量的增减，并且这种影响可以通过历史数据来量化和预测。

4、人员排班和劳动法规：假设每个分拣中心都遵守当地劳动法规，包括工作时间、连续工作日数限制和休息时间等，并且可以根据需求调整正式工和临时

工的人数，且临时工的调整可以在短时间内进行。

5、工作平衡：假设特定分拣中心的排班需要平衡正式工的出勤率，使其不超过 85%，并且尽量均匀分配工作日，以避免劳动力集中和疲劳。

6、稳定的市场需求：假设市场需求是相对稳定的，即在预测的时间段内，市场需求不会受到剧烈的波动或突发事件的影响。

7、稳定的供应链环境：假设供应链的环境相对稳定，包括供应商、运输网络和分销渠道等方面的稳定性，以便进行准确的预测和规划。

8、工作效率假设：假设在排班安排下，工作人员的工作效率是相对稳定和可预测的，不受到外部因素的影响。

这些假设为我们建立模型提供了一些先验知识和限制条件，帮助我们更好地理解问题的背景和范围，以及在模型建立和预测过程中需要考虑的因素。

3 问题一

3.1 数据描述和问题一分析

该物流网络包括 57 个分拣中心，每个分拣中心过去 4 个月的每天货量数据以及过去 30 天的每小时货量数据。我们选取了 8 个分拣中心每个月货量的平均值进行统计，绘制的折线统计图如下图 4-1 所示；对 SC48 分拣中心某两天每个小时的货量进行统计，绘制的折线统计图如下图 4-2 所示。




图 3-1 分拣中心每个月货量平均值折线图




图 3-2 SC48 分拣中心每小时的货量

从图 1 和图 2 的统计结果可知,分拣中心的货量在不同月份以及每天的不同时段都有其周期性变化的趋势。因此我们可以采用时间序列预测算法来解决货量的预测问题。

3.2 模型的建立

时间序列任务时间序列数据预测任务是指利用过去的时间序列数据来预测未来的数值或趋势。这种任务通常涉及到对时间序列中的趋势、季节性、周期性以及随机噪声等方面进行建模,以便进行准确的预测。

LSTM 模型, LSTM 全称为长短期记忆 (Long Short-Term Memory) 网络,是一种特殊的递归神经网络 (RNN)。与传统的前馈神经网络不同, LSTM 能够利用时间序列对输入数据进行分析,这使得它在处理诸如自然语言处理 (NLP) 或者连续数据点 (例如股票价格) 等任务时表现出色。LSTM 的核心在于它的内部门结构,这些门能够控制信息的存储、更新和遗忘。这样的设计使得 LSTM 能够解决传统 RNN 面临的梯度消失和梯度爆炸问题,从而有效地学习和记忆长期依赖关系。LSTM 的结构如下图所示:




图 3-3 LSTM 模式的四个交互层

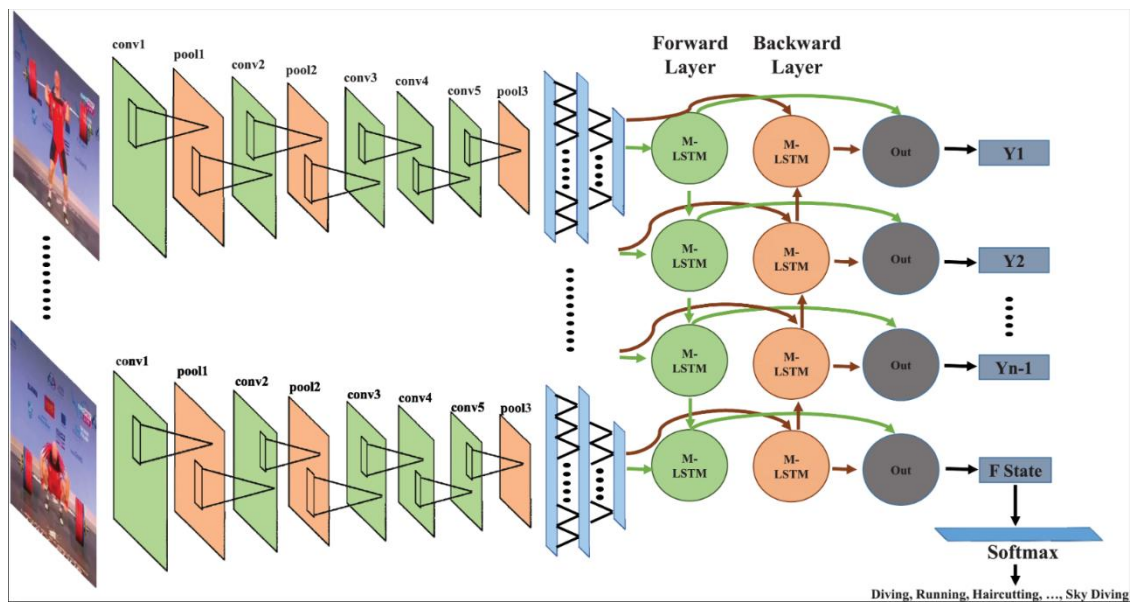


图 3-4 LSTM 网络结构

神经网络节点计算公式如下：

$$\begin{aligned}
 i_t &= \sigma(W_{ii}x_t + b_{ii} + W_{hi}h_{(t-1)} + b_{hi}) \\
 f_t &= \sigma(W_{if}x_t + b_{if} + W_{hf}h_{(t-1)} + b_{hf}) \\
 g_t &= \tanh(W_{ig}x_t + b_{ig} + W_{hg}h_{(t-1)} + b_{hg}) \\
 o_t &= \sigma(W_{io}x_t + b_{io} + W_{ho}h_{(t-1)} + b_{ho}) \\
 c_t &= f_t * c_{(t-1)} + i_t * g_t \\
 h_t &= o_t * \tanh(c_t)
 \end{aligned} \tag{1}$$

其中 i_t 表示输入门，决定了多少新的输入信息应该被加入到细胞状态中。这里的 σ 表示 sigmoid 激活函数， W_{ii} 和 b_{ii} 分别表示权重和偏置项， x_t 是当前时间步的输入， $h_{(t-1)}$ 是前一个时间步的隐藏状态。

f_t 表示遗忘门，控制着从细胞状态中丢弃什么信息。这同样使用 sigmoid 函数来决定哪些信息保留，哪些信息遗忘。

g_t 表示候选值，是一个可能会被加入到细胞状态的新信息。这里使用的是 tanh 激活函数，它可以输出介于-1 和 1 之间的值。

o_t 表示输出门，决定了下一个隐藏状态应该包含多少当前细胞状态的信息。这也是通过 sigmoid 函数来计算的。

c_t 表示细胞状态，是 LSTM 单元的“记忆”部分，它结合了过去的信息（通过遗忘门）和新的信息（通过输入门和候选值）。

h_t 表示隐藏状态，包含了当前时间步的输出信息，它是细胞状态的一个过滤版本，由输出门控制。

3.3 问题一求解

本文需要利用历史货量数据对货量进行预测即为一个时间序列预测任务，我们构建 LSTM 模型来对货量进行预测。以 SC48 分拣中心的数据作为示例，首先我们对数据进行标准化操作，再将时间序列数据转换为监督学习问题所需的输入特征和目标值。然后，我们将构建好的数据输入 LSTM 模型中进行训练，训练了 2 个 LSTM 模型，分别对每天及每小时的货量进行预测。训练好后模型的测试结果入下图 5 所示：

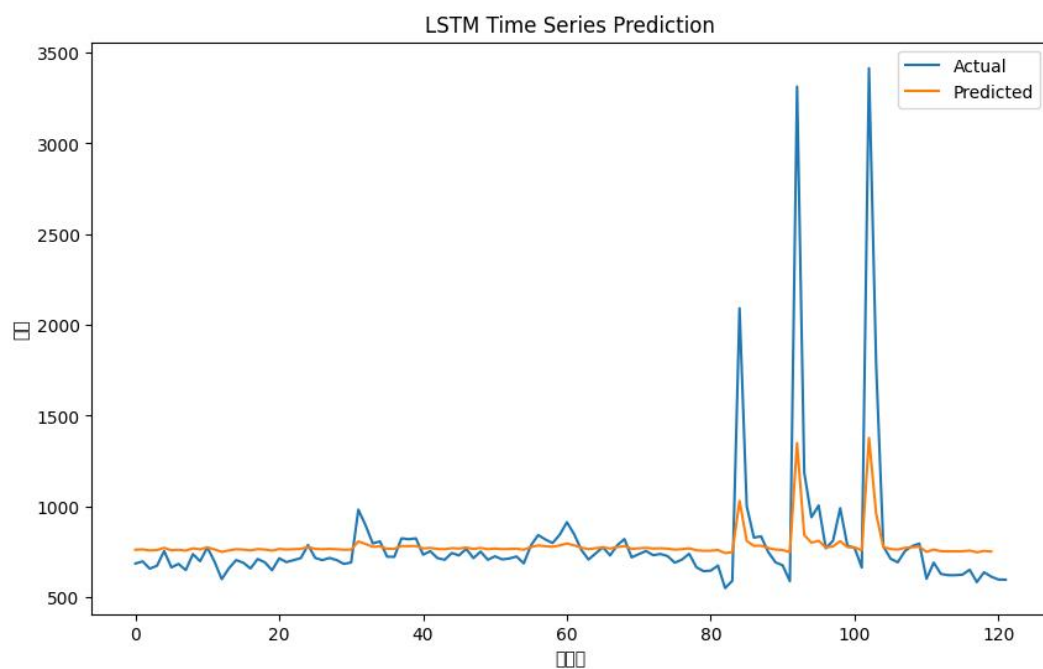


图 3-5 LSTM 每日货量预测结果




图 3-6 LSTM 每小时货量预测结果

通过计算得到了模型的 RMSE 为: 32.6859，可以看出 LSTM 模型具有较好的预测效果。因此，我们分别对 57 个分拣中心未来 30 天每天及每小时的货量进行预测，并把结果写入结果表 4-1 和表 4-2 中。部分预测的结果如表 4-1、表 4-2 所示

表 3-1 未来 30 天每天货量预测结果

分拣中心	日期	预测货量	预测货量(取整)
SC48	2024/4/12	770.654792	770
SC48	2024/4/13	798.2795019	798
SC48	2024/4/14	802.8281794	802
SC48	2024/4/15	803.5818539	803
SC48	2024/4/16	803.7068546	803
SC48	2024/4/17	803.7275742	803
SC48	2024/4/18	803.7310097	803
SC48	2024/4/19	803.7315859	803
SC48	2024/4/20	803.7316926	803
SC48	2024/4/21	803.7316926	803

表 3-2 未来 30 天每小时货量预测结果

分拣中心	日期	小时	预测货量
SC54	2023/12/1	1	106.8180391
SC54	2023/12/1	2	106.8180391
SC54	2023/12/1	3	106.8180391
SC54	2023/12/1	4	106.8180391
SC54	2023/12/1	5	106.8180391
SC54	2023/12/1	6	106.8180391
SC54	2023/12/1	7	106.8180391
SC54	2023/12/1	8	106.8180391
SC54	2023/12/1	9	106.8180391
SC54	2023/12/1	10	106.8180391

4 问题二

4.1 数据描述与问题二分析

此文新增了分拣中心各个运输路线过去 90 天的平均货量数据，我们对数据进行可视化，做出的分拣中心不同路线货量统计气泡图如下图 6 所示，气泡的颜色越深气泡越大说明这条线路的货量越大，从图中我们可以看出从 SC6 到 SC12 这条路线的货量是最大的，同时也可以发现有很多路线的货量比较小，因此不同路线的货量的差异是比较大的，这可以作为我们预测分拣中心货量的一个重要条件。

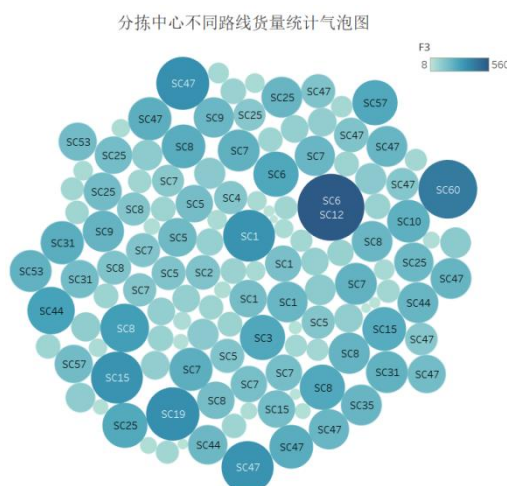


图 4-1 同路线货量统计气泡图

4.2 问题二求解

问题 2 需要对 57 个分拣中心未来 30 天每天及每小时的货量进行预测。我们首先将附件三中的涉及的数据进行处理，然后利用始发分拣中心、到达分拣中心的路线、货量作为特征构建 LSTM 模型。对于新增路线，我们对附件三、四进行合并确定新增运输路线的情况，以附件 3 中的平均货量作为其初始货量。模型的训练与第一问的过程类似，先把输入数据处理为 LSTM 模型需要的输入数据格式，然后构建 LSTM 模型训练 100 个 epoch 得到我们的预测模型。最后，用训练得到的模型对附件 4 中每个分拣中心的货量进行预测并将预测结果保存到结果 3、结果 4 文件中。

5 模型评估与进一步讨论

5.1 模型的优点

利用 LSTM 来处理和预测时间序列数据，可以有效地处理长序列数据并且不会受到梯度消失或梯度爆炸的影响。

5.2 模型的缺点

LSTM 模型通常需要大量的数据进行训练，以学习数据之间的复杂关系，如果数据量不足，容易导致过拟合。

5.3 总结

电商物流网络中，分拣中心是一个关键的环节，负责将订单按照不同的流向进行分拣以便将包裹送达到消费者手中。本文主要根据分拣中心的历史货量与物流网络配置等信息来预测分拣中心每天或者每小时的货量，为电商物流网络的顺畅运作提供支持。

6 参考文献

- [1] 李宁. 物流配送网络规划问题研究 [D]. 北京交通大学 [2024-04-13]. DOI:10.7666/d.y1963088.
- [2] 袁际军. 现代物流配送路线优化研究 [D]. 武汉理工大学 [2024-04-13]. DOI:10.7666/d.y674307.
- [3] 张惠玲, 鲁鹏, 牟智伟, 等. 护士排班问题的研究 [J]. 管理学家: 学术版, 2014(1):2. DOI:10.3969/j.issn.1674-1722.2014.01.577.
- [4] 李加加, 沈吟东. 基于演化算法的多级别多岗位护士排班问题研究 [C]//第 36 届中国控制会议论文集 (B). 2017.
- [5] Nair, Vinod et al. "Solving Mixed Integer Programs Using Neural Networks." ArXiv abs/2012.13349 (2020): n. pag.
- [6] 李文静, 王潇潇. 基于简化型 LSTM 神经网络的时间序列预测方法 [J]. 北京工业大学学报, 2021, 47(5): 480-488. DOI: 10.11936/bjutxb2020120032
- [7] 王英伟, 马树才. 基于 ARIMA 和 LSTM 混合模型的时间序列预测 [J]. 计算机应用与软件, 2021. DOI:10.3969/j.issn.1000-386x.2021.02.047.